

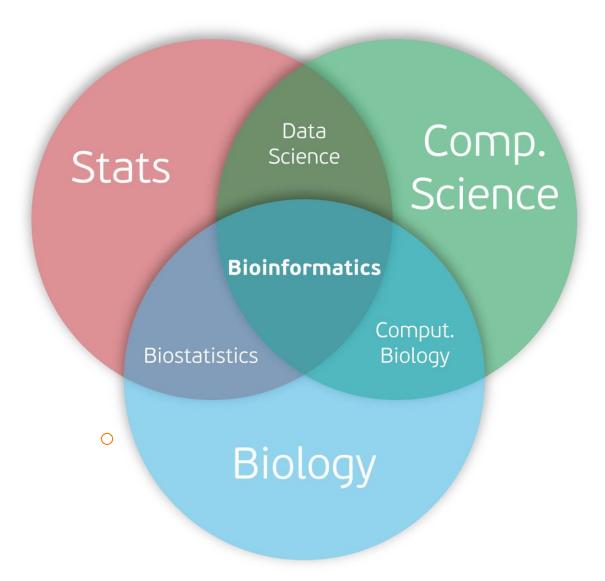
### How does the "stuff" happen?

Miglė Survilaitė



### Šiek tiek apie mane

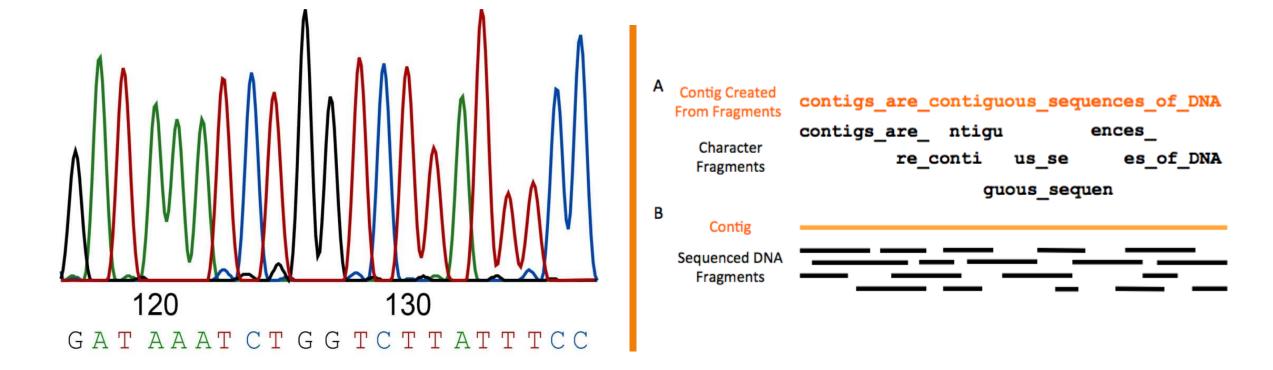
- 2012 2016 Bakalauro studijos Vilniaus Universitete, Biochemija
- 2016 2018 Magistro studijos Kopenhagos Universitete, Bioinformatika
- 2017 ... bio.tools, bioinformatinių tools'ų kuravimas
- 2017 ... Genominės medicinos centras,
   Rigshospitalet



### Kas ta bioinformatika?

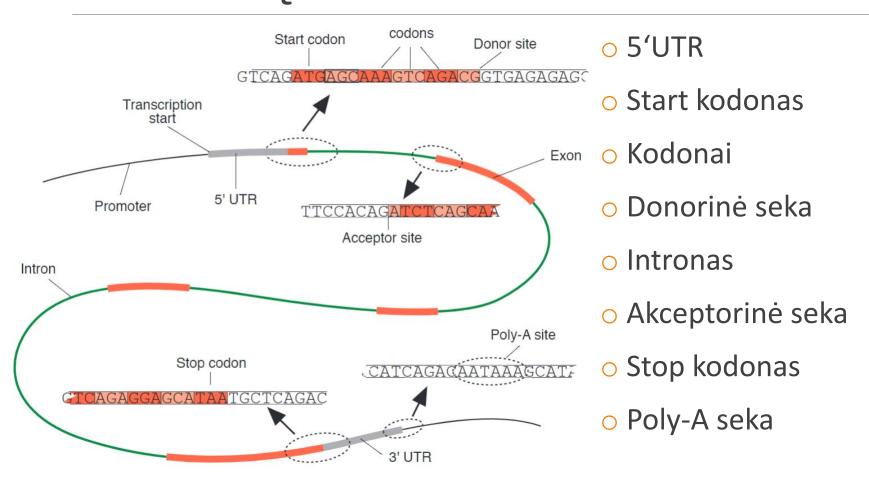
- Wikipedia:
  - Bioinformatics is an interdisciplinary field that develops methods and software tools for understanding biological data.
- Even better:
  - Bioinformatics is an interdisciplinary field that develops and applies methods and software tools for understanding biological data.
- o Pagrindiniai bioinformatikų tipai?

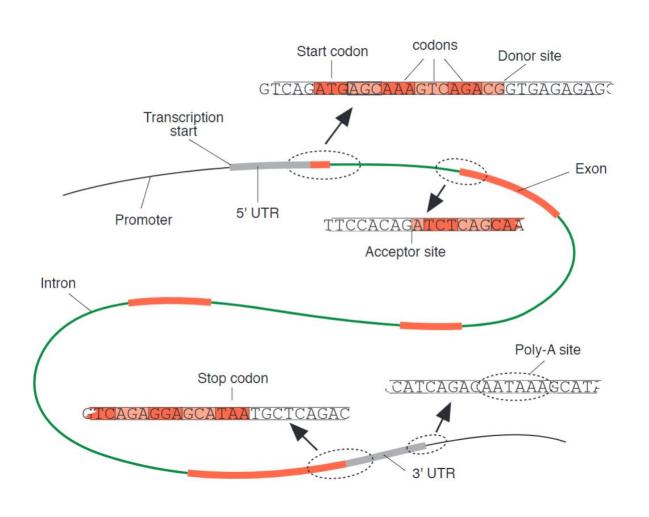
# Kaip atpažinti genus iš sekoskaitos rezultatų?

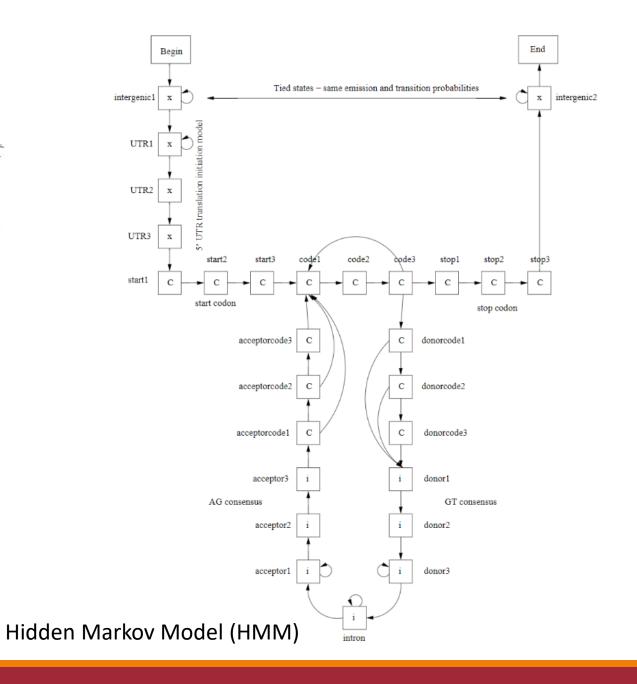


### Kas yra sekoskaita?

### Kaip atpažinti genus iš sekoskaitos rezultatų?







## Kaip atpažinti genus iš sekoskaitos rezultatų?

Realybėje viskas daug sudėtingiau ©

#### Ką gali bioinformatika?

- Sequence analysis
- Structural bioinformatics
- Phylogenetic analysis/population genetics
- Bioinformatics of high-throughput analysis
- Statistics, visualizations

#### FASTA formatas

- Daugumos sequence analysis tools'ų input formatas yra FASTA.
- o FASTA failai susideda iš sekos pavadinimo (1 eilutė prasidedanti > ženklu) ir nukleotidų/aminorūgščių sekos.
- Pavyzdys:
  - > Some fancy name

TACAANAAAATTAGCCAGGCATGATNGTGCATGNCTATGGTCCCANNTNCNNGGNAGGCTGAGGCAGGAGNATNGNTTGAACCTGN GANGNNNNGGNTNCAGTNNNNCANGNTNNCNCNNNNNGCNNTCCCGNNNNNNGNANNNGNGCNNNNC

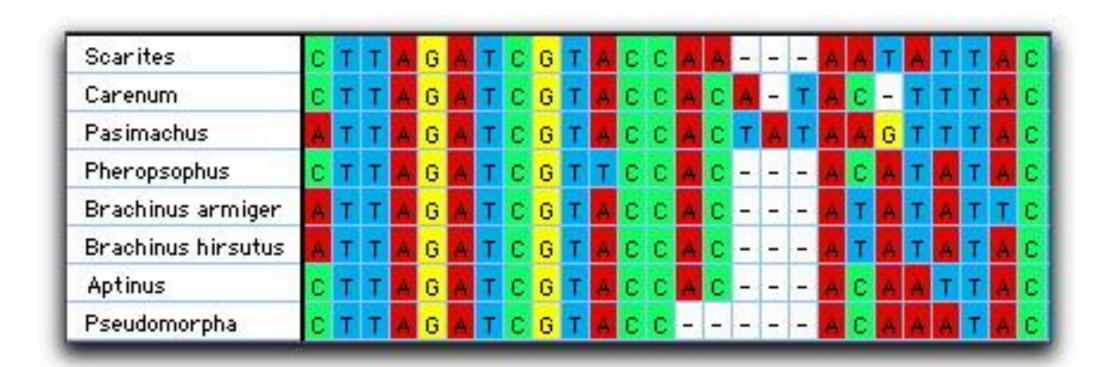
FASTQ failai susideda iš 4 eilučių (@ prasidedantis sequence identifier; nukleotidų/aminorūgšių seka; + (ir optional sequence identifier); nukleotidų/aminorūgščių quality scores)

@NS500314:279:HFT5JBGX5:1:11101:4769:1044 1:N:0:AGTCAA

AGGAANTAAAATTAAATATGTCTTCNTCCACCTNAGCCAGGGATGNNANCNNCTNCTGTGAGCCCTGGACNCTNANCATGCAGCCNG CNCNNNNNANGNTCGNNNNNGCNCNCNNCNGNNNNCCNNTCACANNNNNCNANNNCNTANNN

+

### Sequence alignment – sekų palyginimas



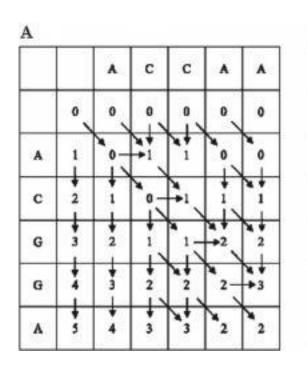
	С	Т	А	А	G
С					
А					
G					

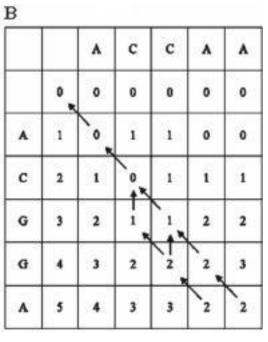
		С	Т	А	А	G
	-	-	-	-	-	-
С	-	1	1	1	1	1
А	-	1	1	2	2	2
G	-	1	1	2	2	3

Match (+1)

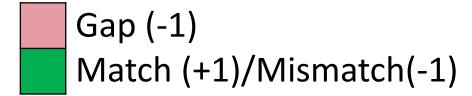
		С	Т	А	А	G
	-	-	-	-	-	-
С	-	1	0	-1	-2	-3
А	-	0	0	-1	0	-1
G	-	-1	-1	-1	-2	1

Gap (-1)Match (+1)/Mismatch (-1)





		С	Т	А	А	G
	-	-	-	-	-	-
С	-	1	0	-1	-2	-3
Α	-	0	0	-1	0	-1
G	-	-1	-1	-1	-1	1

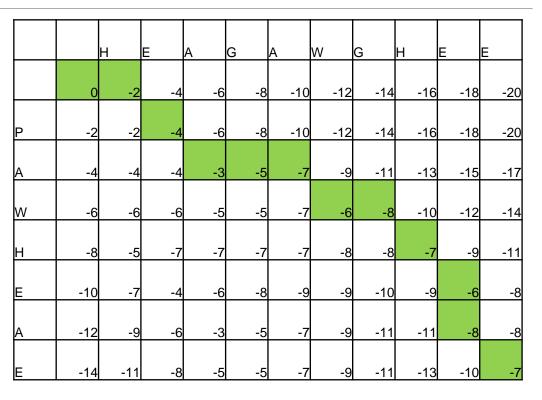


	Α	С	D	Е	F	G	Н	Τ	K	L	М	N	Р	Q	R	s	Т	٧	W	Υ
Α	5	-1	-2	-1	-3	D	-2	-1	-1	-2	-1	-1	-1	-1	-2	1	0	0	9	-2
С	-1	13	-4	-3	-2	-3	9	-2	-3	-2	-2	-2	-4	-3	-4	-1	-1	-1	ņ	-3
D	-2	-4	8	2	-5	-1	-1	-4	-1	-4	-4	2	-1	0	-2	0	-1	-4	-5	-3
E	-1	-3	2	6	-3	'n		-4	1	-3	-2		-1	2		-1	-1	'n	η	-2
F	-3	-2	-5	-3	8	-4	-1	0	4	1	0	-4	-4	-4	-3	-3	-2	-1	1	4
G	0	-3	-1	-3	-4	8	-2	-4	-2	-4	-3	0	-2	-2	-3	0	-2	4	ကု	-3
Н	-2	-3	-1	0	-1	-2	10	-4	0	-3	-1	1	-2	1	0	-1	-2	4	ကု	2
1	-1	-2	-4	-4	0	-4	-4	5	-3	2	2	-3	-3	-3	-4	-3	-1	4	-3	-1
K	-1	-3	-1	1	-4	-2	0	-3	6	-3	-2	0	-1	2	3	0	-1	-3	ņ	-2
L	-2	-2	-4	-3	1	-4	7	2	-3	5	3	-4	-4	-2	-3	-3	-1	1	2	-1
М	-1	-2	-4	-2	0	-3	-	2	-2	$_{\odot}$	7	-2	-3	0	-2	-2	-1	1	۲-	0
Ν	-1	-2	2	0	-4	D	1	-3	0	-4	-2	7	-2	0	1	1	0	-3	4	-2
Р	-1	-4	<b>1</b> −	-1	-4	-2	-2	-3	-1	-4	7	-2	10	-1	-3	-1	<del>-</del>	-3	4	-3
Q	-1	-3	0	2	-4	-2	Τ-	-3	2	-2	0	0	-1	7	Τ-	$\bigcirc$	7	-3	<b>-</b>	-1
R	-2	-4	-2		-3	-3		-4	3	ņ	7	-1	-3	1	7	_	-1	-3	ņ	-1
S	1	-1	0	-1	-3	D	-1	-3	0	ကု	-2	1	-1	0	ς.	5	2	-2	4	-2
T	0	-1	-	-1	-2	-2	7	-1	-1	-1	-1	0	-1	-1	-	2	5	0	ကု	-2
٧	0	-1	-4	-3	-1	-4	-4	4	-3	1	1	-3	-3	-3	-3	-2	0	5	ကု	-1
W	-3	-5	-5	-3	1	-3	-3	-3	-3	-2	-1	-4	-4	- 1	-3	-4	-3	-3	15	2
Υ	-2	-3	-3	-2	4	-3	2	-1	-2	-1	0	-2	-3	-1	-1	-2	-2	-1	2	8

	Н	E	A	G	A	W	G	Н	E	E
Р	-2	-2	-2	-2	-2	-2	-2	-2	-2	-2
A	-2	-2	1	-2	1	-2	-2	-2	-2	-2
W	-2	-2	-2	-2	-2	1	-2	-2	-2	-2
Н	1	-2	-2	-2	-2	-2	-2	1	-2	-2
E	-2	1	-2	-2	-2	-2	-2	-2	1	1
A	-2	-2	1	-2	1	-2	-2	-2	-2	-2
E	-2	1	-2	-2	-2	-2	-2	-2	1	1

Gap penalty -2

	Α	С	D	Е	F	G	Н	Τ	K	L	М	N	Р	Q	R	s	Т	٧	W	Υ
Α	5	-1	-2	-1	-3	D	-2	-1	-1	-2	-1	-1	-1	-1	-2	1	0	0	-3	-2
С	-1	13	-4	-3	-2	-3	-3	-2	-3	-2	-2	-2	-4	-3	-4	-1	-1	-1	-5	-3
D	-2	-4	8	2	-5	-1	-1	-4	-1	-4	-4	2	-1		-2	0	-1	4	5	-3
E	-1	-3	2	6	-3	'n		-4	1	-3	-2		-1	2		-1	-1	'n	η	-2
F	-3	-2	-5	-3	8	-4	-1	0	4	1	0	-4	-4	-4	-3	-3	-2	-1	1	4
G	0	-3	-1	-3	-4	8	-2	-4	-2	-4	-3	0	-2	-2	-3	0	-2	4	ကု	-3
Η	-2	-3	-1	0	-1	-2	10	-4	0	-3	- 1	1	-2	1	0	-1	-2	4	ကု	2
I	-1	-2	-4	-4	0	-4	-4	5	-3	2	2	-3	-3	-3	-4	-3	-1	4	-3	-1
K	-1	-3	-1	1	-4	-2	0	-3	6	-3	-2	0	-1	2	3	0	-1	-3	ņ	-2
L	-2	-2	4	-3	1	-4	7	2	-3	5	3	-4	-4	-2	-3	-3	-1	1	2	-1
М	1	-2	4	-2	0	-3	-	2	-2	თ	7	-2	3	0	-2	-2	-1	1	۲-	0
Ν	-	-2	2	0	-4	D	1	-3	0	-4	-2	7	-2	$\bigcirc$	-1	1	0	-3	4	-2
Р	-1	-4	- 1	-1	-4	-2	-2	-3	-1	-4	-3	-2	10	-1	-3	-1	-1	-3	4	-3
Q		-3	$\circ$	2	-4	-2	1	-3	2	-2	0	0	7	7	1	0	-1	-3	<b>~</b>	-1
R	-2	-4	-7		-3	-3		-4	3	ņ	-2	-1	미	1	7	-1	-1	-3	ņ	-1
s	1	-1	0	-1	-3	D	-1	-3	0	-3	-2	1	-1	0	-1	5	2	-2	4	-2
T		-1	_	-1	-2	-2	7	-1	-1	-1	-1	0	-1	-1	-1	2	5	0	ကု	-2
٧	0	-1	-4	-3	-1	-4	-4	4	-3	1	1	-3	-3	-3	-3	-2	0	5	က္	-1
W	-3	-5	-5	-3	1	-3	-3	-3	-3	-2	-1	-4	-4	-1	-3	-4	-3	-3	15	2
Υ	-2	-3	-3	-2	4	-3	2	-1	-2	-1	0	-2	-3	-1	-1	-2	-2	-1	2	8



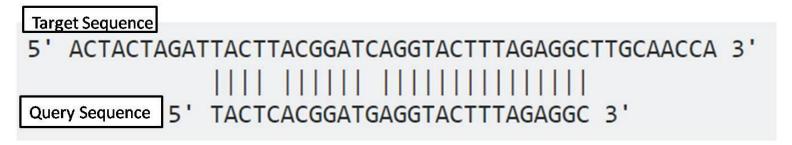
Gap penalty -2

### Pairwise alignment – gap penalty

- Scoring matrix:
  - o PAM
  - BLOSUM
- Linear netenkamas vienodas kiekis taškų už kiekvieną gap'ą
  - $\circ \gamma(g) = -gd$ 
    - o g − gap length
    - o d − gap penalty
- Affine netenkama daugiau taškų už gap'o iniciavimą ir mažiau už gap'o extendinim'ą
  - $\circ \gamma(g) = -d (g-1)e$ 
    - og gap length
    - o d − gap-open penalty
    - o e − gap extention penalty

### Local vs global alignment

#### **Local Alignment**



#### **Global Alignment**

#### Pairwise alignment with linear gap score

#### GLOBAL (NEEDLEMAN-WUNCSH)

$$F_{(i,j)} = \max \begin{cases} F_{(i-1,j-1)} + s(x_i, y_i) \\ F_{(i,j-1)} - d \\ F_{(i-1,j)} - d \end{cases}$$

$$F_{(i,0)} = -id$$

$$F_{(0,j)} = -jd$$

 $F_{(i,j)}$  - matricos pozicija

d - gap penalty

s - score

LOCAL (SMITH-WATERMAN)

$$F_{(i,j)} = \max \begin{cases} F_{(i-1,j-1)} + s(x_i, y_i) \\ F_{(i,j-1)} - d \\ F_{(i-1,j)} - d \\ 0 \end{cases}$$

### BLAST – Basic Local Alignment Search Tool

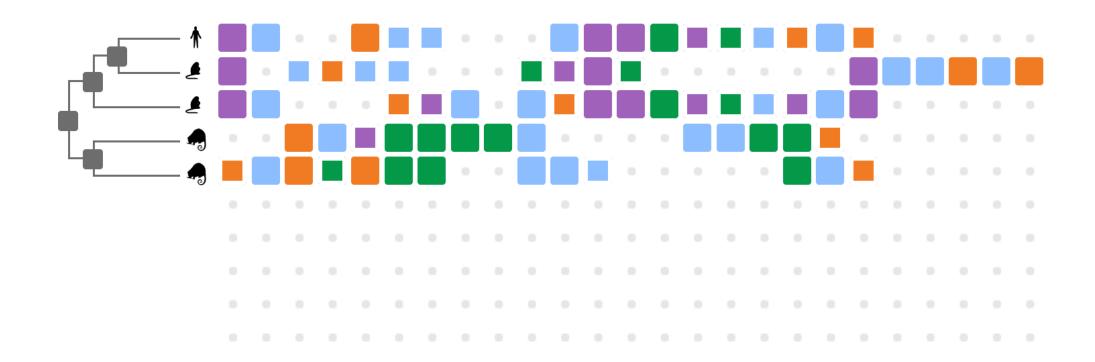
- Heuristinis metodas mažesnis jautrumas/tikslumas, sutaupoma laiko ir vietos (storage)
- Identifikuojami trumpi sutampantys regionai (žodžiai)
- Jei žodžio score yra didesnis nei riba (threshold), žodis yra plečiamas (extended) į abi puses be gap'ų
- Algoritmas sustoja plėsti alignment'ą, kai žodis pasiekia maksimalią taškų sumą
- Naujos BLAST versijos bando sujungti kelis alignment'us tarp kurių yra gap'as

#### BLAST – praktinė užduotis

- Nueikite į UNIPROT duomenų bazę (<a href="http://www.uniprot.org/">http://www.uniprot.org/</a>) ir raskite P38398 baltymą.
- Kairėje pasirinkite Sequences ir atsidarykite Isoform1 FASTA formatu
- Nukopijuokite seką į BLAST webserver'į (<a href="http://blast.ncbi.nlm.nih.gov/Blast.cgi">http://blast.ncbi.nlm.nih.gov/Blast.cgi</a>), pasirinkite blastp (baltymų sekoms) ir paleiskite su default parametrais
- Kokių organizmų sekas gaunate? Ar tai tik žmogaus genomo sekos? Kokias išvadas galima daryti iš pateiktų BLAST rezultatų?

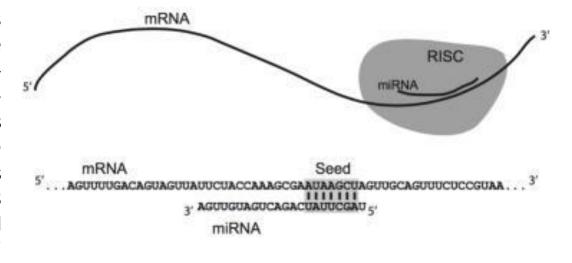
### Multiple sequence alignment – 5 minutės žaidimo

http://phylo.cs.mcgill.ca/tutorial/index.html#EN



### Motif discovery - užduoties įvadas

A microRNA (miRNA) is a small RNA molecule, around 22 bases long, which regulates gene expression by inhibiting the translation of mRNAs. A miRNA is incorporated into the RNAinduced silencing complex (RISC), which facilitates the basepairing of the miRNA with the target single stranded mRNA. This yields a partially double stranded mRNA which cannot be translated by the ribosome. Most often the mRNA target site is complementary to the sequence going from positions 2-7 or 2-8 of the miRNA. The complementary region in the mRNA is called a seed site. Normally the seed sites are located in the 3' untranslated part of the mRNA (the 3'UTR) An example for the human miRNA 21 (hsa-mir-21) is in the right.



How can one identify the target sites of a particular miRNA? The idea is simply to perturb the expression levels of the miRNA and then do a **motif finding analysis** on the set of up or down regulated genes. The perturbation is most commonly done in two ways. In the first one you transfect into the cell multiple copies of the miRNA of interest, thereby increasing the cellular levels of the corresponding miRNA, which in turn enhances the repression of the miRNA target genes. In the second one you introduce in the cell a sequence which is complementary to the miRNA, which will bind the miRNA and thus it will block its binding to the seed site. Thus, in contrast to the first approach, in this case the function of the miRNA will be inhibited.

#### Motif discovery - užduotis

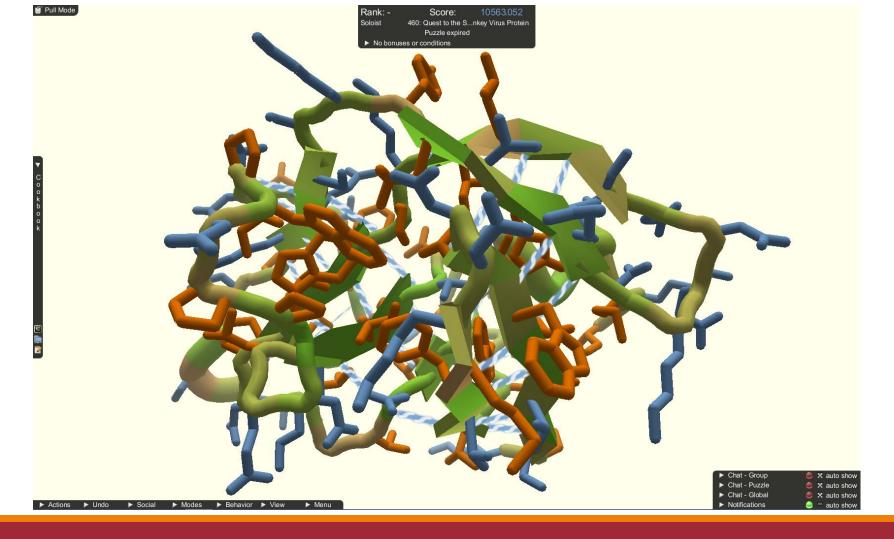
- Eksperimento metu žmogaus ląstelių linija buvo transfekuota miR-16, 500 labiausiai upregulated genų buvo naudojami tolimesnėje analizėje
- Nueikite į MEME webserver'į (<a href="http://meme-suite.org/tools/meme">http://meme-suite.org/tools/meme</a>)
- o Įkelkite pateiktą FASTA failą (PUM2.top500.fa) į MEME webserver'į ir paleiskite su *default* parametrais
- Pasirinkite HTML output'ą, naudodamiesi pateiktais LOGO atsakykite į pateiktus klausimus
- Ar visi identifikuoti motyvai yra vienodai tikėtini būti true positives?
- Ar galite pasakyti kokį motyvą didžiausia tikimybė rasti pagal MEME? Jei motyvas nėra visiškai konservatyvus, kokia yra labiausiai specifinė seka?
- o Kokią išvadą apie miR-16 seed site galima daryti iš gautų rezultatų?

#### Tools'ai sekų analizei

- Pairwise alignment:
  - BLAST <a href="https://blast.ncbi.nlm.nih.gov/Blast.cgi">https://blast.ncbi.nlm.nih.gov/Blast.cgi</a>
  - Needle (global) PROTEIN <a href="https://www.ebi.ac.uk/Tools/psa/emboss-needle/">https://www.ebi.ac.uk/Tools/psa/emboss-needle/</a>
  - Needle (global) NUCLEOTIDE <a href="https://www.ebi.ac.uk/Tools/psa/emboss-needle/nucleotide.html">https://www.ebi.ac.uk/Tools/psa/emboss-needle/nucleotide.html</a>
  - Water (local) PROTEIN <a href="https://www.ebi.ac.uk/Tools/psa/emboss\_water/">https://www.ebi.ac.uk/Tools/psa/emboss\_water/</a>
  - Water (local) NUCLEOTIDE <a href="https://www.ebi.ac.uk/Tools/psa/emboss-water/nucleotide.html">https://www.ebi.ac.uk/Tools/psa/emboss-water/nucleotide.html</a>
- Multiple sequence alignment:
  - Clustal W/Clustal Ω <a href="https://www.ebi.ac.uk/Tools/msa/clustalo/">https://www.ebi.ac.uk/Tools/msa/clustalo/</a>
  - MUSCLE (protein) <a href="https://www.ebi.ac.uk/Tools/msa/muscle/">https://www.ebi.ac.uk/Tools/msa/muscle/</a>
  - T-Coffee <a href="https://www.ebi.ac.uk/Tools/msa/tcoffee/">https://www.ebi.ac.uk/Tools/msa/tcoffee/</a>
  - Visualization Jalview http://www.jalview.org/
- Motif discovery:
  - MEME http://meme-suite.org/tools/meme

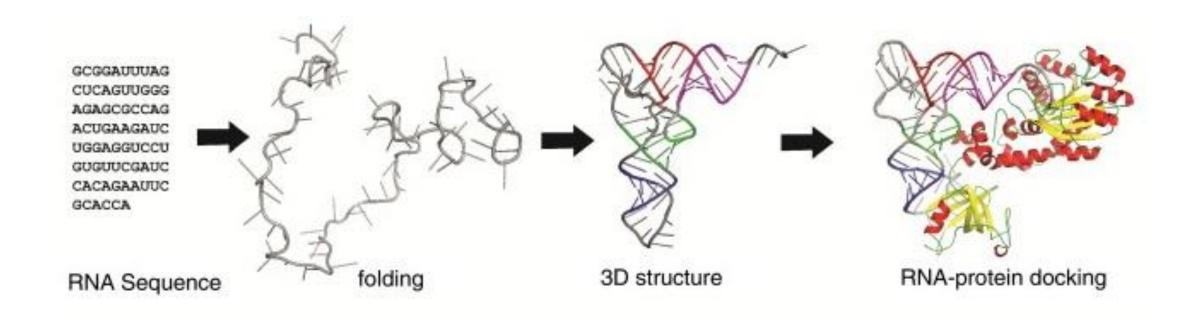
### Struktūrinė bioinformatika

- Baltymų struktūrų analizė
- o RNR struktūrų analizė



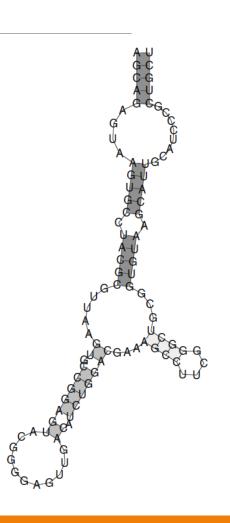
Fold.it

#### RNR erdvinės struktūros

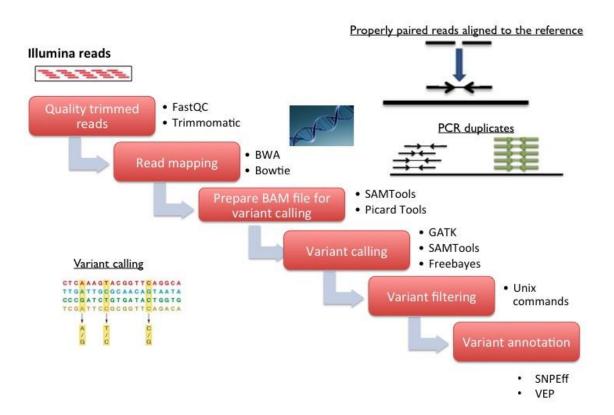


#### RNR struktūrų analizės užduotis

- Nukopijuokite RNR seką į RNAfold webserver'į ir paleiskite su default parametrais (<a href="http://rna.tbi.univie.ac.at/cgi-bin/RNAWebSuite/RNAfold.cgi">http://rna.tbi.univie.ac.at/cgi-bin/RNAWebSuite/RNAfold.cgi</a>)
  - AGCAGAGUAAGUGCCUACGCGUUAAGUGCCGGAGUACGGGGAGUUGACAUCUGGA CGAAAGCCUUCGGGCUGCGGUGUAAGCAUUGCAUCCCGCUGCU
- O Palyginkite gautą struktūrą (MFE) su struktūra, pavaizduota skaidrės dešinėje
- Nueikite į RNR anotacijų duomenų bazę Rfam (<a href="http://rfam.xfam.org/">http://rfam.xfam.org/</a>) ir raskite
   RF01831 RNR šeimą (<a href="http://rfam.xfam.org/">Jump to</a>), pasirinkite pirmas 10 sekų multiple alignmen'us (Eikite į Alignment, tuomet download/view (pasirinkite View) FASTA alignment in gapped format)
- Paleiskite rastas 10 sekų su RNAalifold naudojant default parametrus (<a href="http://rna.tbi.univie.ac.at/cgi-bin/RNAWebSuite/RNAalifold.cgi">http://rna.tbi.univie.ac.at/cgi-bin/RNAWebSuite/RNAalifold.cgi</a>)
- Palyginkite gautą struktūrą su struktūra, pavaizduota skaidrės dešinėje, ir struktūra iš RNAfold webserver'io? Kodėl matote jų skirtumus? (Hint: konservatyvios sekos)



### Bioinformatikos panaudojimas medicinoje

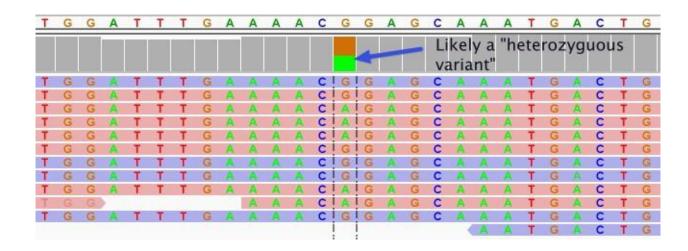


### Bioinformatikos panaudojimas medicinoje

#### **READ MAPPING**

# Paired-end Illumina sequencing Paired-end FASTQ sequences Mapping to the reference genome

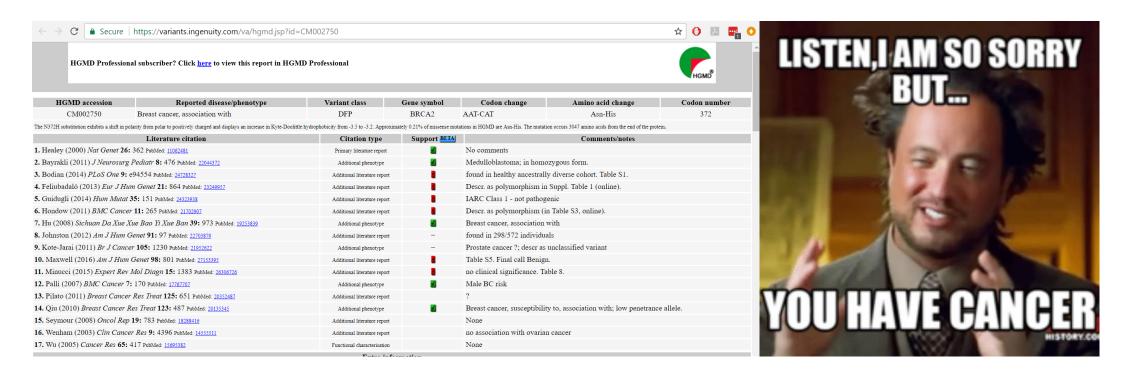
#### **VARIANT CALLING**



### Bioinformatikos panaudojimas medicinoje

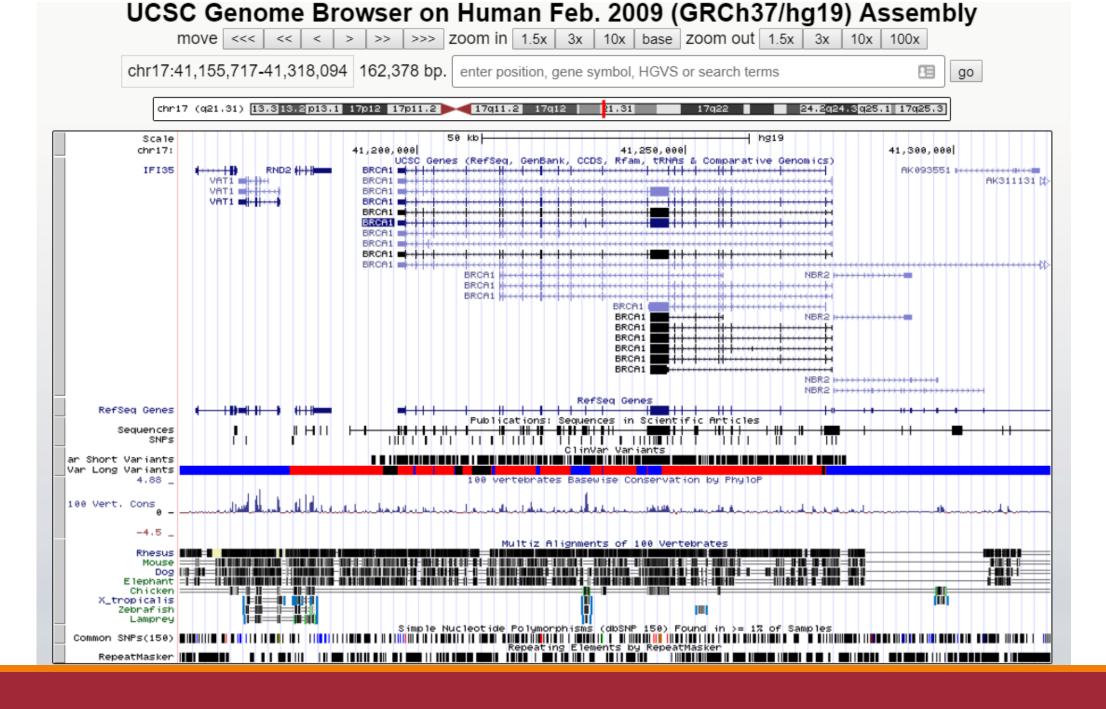
#### VARIANT IDENTIFICATION

#### **DIAGNOSIS**



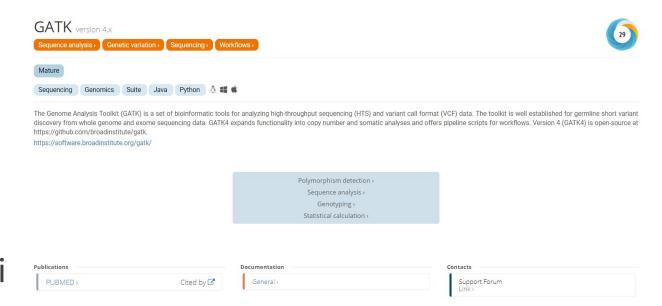
#### UCSC genome browser

- Nueikite į UCSC genome browser'į (<a href="https://genome.ucsc.edu/">https://genome.ucsc.edu/</a>) ir pasirinkite *Genomes*, Human hg19
- Nueikite j chr17:41,155,717-41,318,094
- O Žemiau galima pasirinkti skirtingus track'us priklausomai nuo to, ko ieškote
- Spustelėjus ant track'o pateikiama informacija apie jį
- Galimybė kurti custom track'us

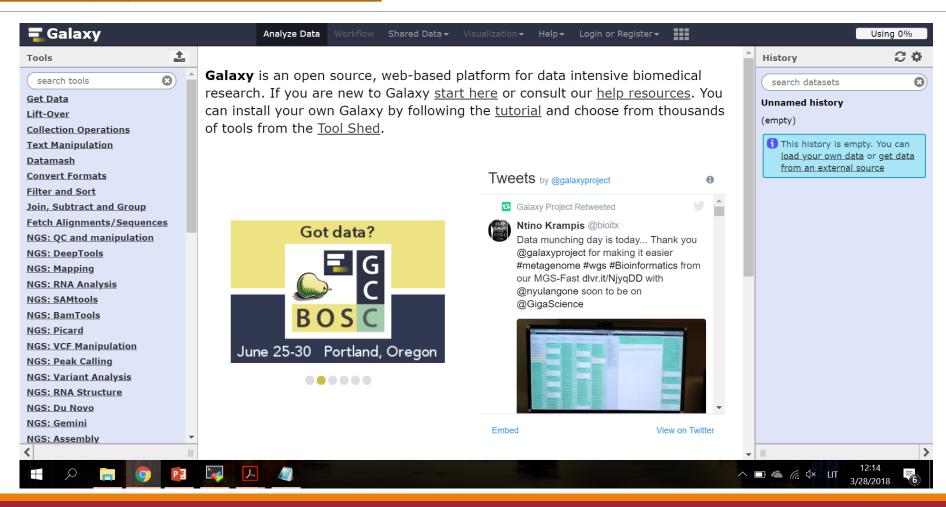


### Kur rasti specifinių bioinformatinių tools'ų?

- Google
- bio.tools
- o mictools.com
- mybiosoftware.com
- Kolegos, draugai, forumai



# Galaxy - <u>usegalaxy.org/</u> arba galaxy.pasteur.fr/



### Išvados

